

Alertas cuando llueve y la operación intensifica.
Caso Rappi · Datos + reglas por zona + mensaje en Telegram

Demo técnica

7 de abril de 2026

Qué vamos a ver

- 1 Problema
- 2 Métrica clave: ratio pedidos/repartidor
- 3 Diagnóstico: zonas y horas críticas
- 4 Insight clave: no es solo demanda
- 5 Acción: sistema de alertas y umbrales operativos
- 6 Extensión futura


Rappi pierde eficiencia por desbalance dinámico

- La **oferta** (repartidores conectados) y la **demanda** (pedidos) *no* se equilibran de forma estable: cambian por **zona**, **hora** y **contexto** (clima, día, incentivos).
- Ese desbalance se manifiesta en colas, saturación puntual y decisiones tarde: hacen falta **avisos a tiempo** y **números concretos** (zona, gravedad, cuánto subir incentivos).
- La solución del caso no es un “modelo mágico” a ciegas: primero se **aprende del histórico** (Excel + notebook) y luego el código aplica **reglas claras** y parámetros versionados (calibration.json).

Tres bloques, una idea cada uno

- Módulo 1 Diagnóstico:** con el Excel y el notebook se entiende cómo reacciona cada zona; de ahí salen sensibilidades y umbrales.
- Módulo 2 Motor:** mira el **clima en vivo** (Open-Meteo), aplica las reglas por zona y dice riesgo e incentivos.
- Módulo 3 Mensaje:** convierte ese resultado en **texto para humanos** (modelo de lenguaje o plantilla de respaldo) y lo manda a **Telegram**.

Arquitectura del pipeline



Qué mide el ratio y cómo se etiqueta el panel

- **Definición:** ratio = pedidos entre repartidores conectados en esa celda (zona $\times$ hora); resume el **apretón** operativo relativo.
- **Saturación:** si el ratio supera **1,8** la celda se trata como saturada en el diagnóstico.
- **Otras bandas:** sobre-oferta si $< 0,5$; “saludable” entre 0,9 y 1,2; el resto es intermedio.
- **Panel:** 30 días $\times$ 24 h $\times$ 14 zonas = 10 080 filas en el Excel de referencia.

Variables que se utilizan para calibrar el motor

- `precip_coef` — cuánto sube el “apretón” operativo cuando sube un poco la lluvia (estimado como en el notebook).
- `sensitivity_index` — qué tan “nerviosa” es la zona frente a lluvia, comparada con el resto (número entre 0 y 1).
- `alert_precip_mm_hr` — a partir de cuánta lluvia (mm/h) tiene sentido considerar alerta, según el histórico de horas “malas”.
- `mm_precip_healthy_to_saturation_linear` — orden de magnitud de lluvia para pasar de “normal” a “muy cargado” en esa zona.
- `base_earnings_mxn` — mediana histórica de pagos en la zona.
- `recommended_earnings_mxn` — media cuando ya llovía por encima del umbral (M1); el motor interpola entre base y recomendado según el ratio proyectado (tope global 35 %).

Cosas que el diagnóstico deja en claro

- 1 El panel tiene **30 días × 24 h × 14 zonas** (10 080 filas).
- 2 La lluvia **sí se asocia** con más presión operativa.
- 3 Hay una asociación con patrones temporales específicos, en ciertos horarios del día (Comida y Cena).
- 4 Se observan incrementos en días festivos, así como en días particulares de la semana como jueves y martes.
- 5 Existe una posible influencia de eventos locales, que podrían intensificar la demanda y elevar saturación.
- 6 Si en una hora hay más de **0,5 mm/h** de lluvia, la probabilidad de saturación es unas **8 veces** mayor que con lluvia muy suave o nula.
- 7 **Cada zona es distinta:** por ejemplo Santiago reacciona antes que Mitras.
- 8 **Mapas:** la mayoría de polígonos vienen bien; donde falta, se usan centroides.
- 9 Los resultados deben interpretarse con cautela, ya que pueden estar afectados por variables de confusión.
- 10 Es necesario validar si los efectos observados son causales o circunstanciales.
- 11 Se recomienda incorporar variables como el tipo de zona (urbana vs. rural).

Más detalle: modulo1_diagnostico/HALLAZGOS_M1.md

Clasificación operativa — conteos y % (sobre filas con etiqueta)

clasificacion	<i>n</i> filas	%	Criterio sobre ratio
intermedio	4807	47,69	Resto: $[0,5, 0,9)$ o $(1,2, 1,8]$.
saludable	2503	24,83	$0,9 \leq \text{ratio} \leq 1,2$.
sobre_oferta	2257	22,39	$\text{ratio} < 0,5$.
saturacion	513	5,09	$\text{ratio} > 1,8$.

La columna `clasificacion` resume el estado frente a umbrales de `ratio` del diagnóstico (saludable, saturación, etc.). Los porcentajes son sobre filas con categoría (aquí, las 10 080 con `ratio` válido).

La mayoría del panel está fuera de saturación; $\approx 5\%$ de celdas superan el umbral operativo. IC95 % Wilson para la proporción global en saturación: $[0,0468, 0,0554]$.

P1 — Saturación por hora del día




P1 responde *¿a qué horas aparece más a menudo el ratio por encima del umbral de saturación?* No es predicción; es **conteo** en el historial del Excel.

El gráfico acumula filas con `clasificacion=saturacion (ratio > 1,8)` por hora.

P1 — Horas con mayor fracción empírica de saturación

HOOR	p_{sat}	n
14	0,2786	420
13	0,2595	420
12	0,2452	420
21	0,1619	420
19	0,1238	420
20	0,1214	420
17	0,0095	420
16	0,0071	420

P1 — Zonas con más celdas en saturación



Ordena territorios por **frecuencia histórica** de saturación en el mes. Sirve para priorizar dónde mirar primero; no sustituye criterio de zona en vivo.

P2 — Correlaciones Pearson y MCO

Matriz de correlación de Pearson

	PRECIPITATION_MM	ratio	EARNINGS
PRECIPITATION_MM	1,000000	0,318902	0,226029
ratio	0,318902	1,000000	0,099885
EARNINGS	0,226029	0,099885	1,000000

$P(\text{saturación} \mid \text{precip} > 0,5) = 0,3082$ $P(\text{saturación} \mid \text{precip} \leq 0,5) = 0,0377$


P2 — Lluvia, demanda e interacción (lectura cualitativa)

Hora	Efecto de lluvia
Mañana	Bajo impacto
Comida	Medio
Cena	Muy alto


La lluvia se asocia a más saturación **controlando** por hora y zona, pero el efecto **no es homogéneo**: se **intensifica en horas de alta demanda** (interacción operativa–externa).

La tabla es cualitativa y está alineada con GAP 1 (pendiente marginal por hora).

Exploración — distribución del ratio por zona



GAP 1 — Pendiente marginal de precipitación por hora




Con interacción precipitación $\times$ hora, la **pendiente marginal** de +1 mm/h varía por franja. El gráfico resume Δ ratio por hora (referencia HOUR=0).

P2b — Tabla: saturación y CV(ORDERS) por tramo de ratio

Tramo	n	$p_{\text{saturación}}$	CV(ORDERS)
$< 0,9$	5780	0,0000	1,1828
0,9–1,2	2422	0,0000	0,7761
1,2–1,5	851	0,0000	0,5082
1,5–1,8	514	0,0000	0,3616
$> 1,8$	513	1,0000	0,3685

Proxy de “estrés” por bandas de ratio. Solo el tramo $> 1,8$ coincide con saturación operativa del caso. El CV de pedidos sirve como señal de inestabilidad.

P2b — Estrés por tramo de ratio




Las barras visualizan la misma lógica que la tabla: cómo cambia la fracción ya en saturación y la variabilidad de ORDERS al moverse el ratio por bandas.

P3 — Coef. precipitación por zona (MCO estratificado, 14 zonas)

Zona	β_{precip}
Santiago	0,190569
Carretera Nacional	0,131460
Santa Catarina	0,103332
MTY Apodaca Huinalá	0,085885
Independencia	0,073652
San Pedro	0,068153
Apodaca Centro	0,065663
Escobedo	0,063273
Centro	0,062092
San Nicolás	0,059934
La Fe	0,059660
MTY Guadalupe	0,058108
Cumbres Poniente	0,052032
Mitras Centro	0,049596


Por zona: $\text{ratio} \sim \text{precip.} + C(\text{HOUR}) + C(\text{dow})$. Orden por magnitud de β (mismo criterio que el gráfico P3 del notebook).

P3 — Sensibilidad del ratio a la lluvia por zona



El gráfico ordena territorios por magnitud del coeficiente marginal de precipitación (misma especificación dentro de cada ZONE).

P4 — Earnings diario vs fracción en saturación



Agrega por **día**: earnings medio frente a fracción de celdas en saturación. Sirve para ver días “caros” y estresados. Mezclar solo a nivel día puede confundir demanda e incentivos (véase GAP 4).

P4 — Top 10 días por sat_frac

Fecha	earn. med.	sat_frac	sobre_frac	ratio med.	A investigar (hip. ext.)
2024-03-28	55,86	0,1667	0,1994	1,103	Placebo (Showcenter), The Vaccines (GNP).
2024-03-08	56,22	0,1399	0,2173	0,976	Neblina, Tour "90s Pop" (Arena), 8M
2024-03-25	56,07	0,1310	0,2143	0,896	Sin feriado
2024-03-05	57,17	0,0952	0,2054	0,980	Sin feriado.
2024-03-27	56,66	0,0655	0,2143	0,809	Sin eventos destacados. Sin feriado.
2024-03-14	60,44	0,0506	0,2798	0,746	Portugal. (Showcenter); Ana Bárbara (Arena).
2024-03-16	57,17	0,0506	0,2202	0,800	Tucanes de Tijuana (Arena).
2024-03-01	56,59	0,0476	0,1964	0,831	Camilo Séptimo (Showcenter); Temerarios (Arena);
2024-03-18	56,64	0,0446	0,2024	0,814	Natalicio Benito Juárez, Laura Pausini (Arena).
2024-03-26	56,55	0,0446	0,2173	0,817	Sin feriado.


Notebook: **p75 earn + estrés** solo 2024-03-14; **p75 earn + sobre-oferta** 2024-03-03, 07, 14, 22. Columna *A investigar*: clima, conciertos/eventos y feriados (referencia externa; no está en el Excel del caso).

GAP 5 — *Risk score* por zona (tabla completa, notebook)

Zona	risk	$\hat{P}_{\text{sat}}$	sens. lluvia	demanda
Santa Catarina	0,0832	0,0528	0,1033	8,50
Carretera Nacional	0,0616	0,0597	0,1315	5,86
San Nicolás	0,0507	0,0625	0,0599	12,53
Centro	0,0420	0,0486	0,0621	16,11
Independencia	0,0404	0,0528	0,0737	8,84
MTY Guadalupe	0,0341	0,0611	0,0581	11,42
Apodaca Centro	0,0292	0,0514	0,0657	9,62
San Pedro	0,0164	0,0403	0,0682	13,67
Escobedo	0,0139	0,0500	0,0633	7,66
Cumbres Poniente	0,0017	0,0417	0,0520	9,96
MTY Apodaca Huinalá	0,0000	0,0375	0,0859	4,48
La Fe	0,0000	0,0361	0,0597	7,64
Mitras Centro	0,0000	0,0556	0,0496	11,40
Santiago	0,0000	0,0625	0,1906	4,48

$\text{risk} = \hat{P}(\text{sat}) \times \text{sensibilidad_lluvia} \times \text{demanda}$ con factores min-max por columna en el panel (impreso en consola del notebook). Top 3: Santa Catarina, Carretera Nacional, San Nicolás.

GAP 5 — Risk score por zona




Ranking visual coherente con la tabla; escala normalizada para comparar zonas en un solo gráfico.

Sensibilidad — mm/h para $\Delta\text{ratio} \approx 0,6$ (tabla)

Zona	β_{precip}	mm/h ($\approx 0,6/\beta$)
Santiago	0,1906	3,15
Carretera Nacional	0,1315	4,56
Santa Catarina	0,1033	5,81
MTY Apodaca Huinalá	0,0859	6,99
Independencia	0,0737	8,15
San Pedro	0,0682	8,80
Apodaca Centro	0,0657	9,14
Escobedo	0,0633	9,48
Centro	0,0621	9,66
San Nicolás	0,0599	10,01
La Fe	0,0597	10,06
MTY Guadalupe	0,0581	10,33
Cumbres Poniente	0,0520	11,53
Mitras Centro	0,0496	12,10

Heurística del notebook: $\Delta\text{precip} \approx 0,6/\beta$ si $\beta > 0$ (banda de ratio $1,2 \rightarrow 1,8$). Lectura de orden de magnitud bajo linealidad local.

Sensibilidad — mm/h (gráfico)



Misma información que la tabla anterior en formato barras horizontales.

P5 — Spearman EARNINGS vs ratio (panel completo)

Contraste	Valor (notebook)
Spearman global ($n = 10\,080$)	$\rho \approx 0,0761$
p -valor (dos colas)	$\approx 1,95 \times 10^{-14}$

Correlación de *rangos* (monótona, no lineal) entre tarifa y carga. Complementa Pearson y el MCO con interacción $\text{lluvia} \times \text{EARNINGS}$ en la lámina siguiente.

Lectura exploratoria (Excel + notebook)

- **Al parecer**, las zonas con perfil más **rural o periférico** concentran con mayor frecuencia **anomalías tipo saturación**: distribuciones más anchas y picos extremos (ratio muy alto en ciertas horas), coherentes con episodios de mucha demanda relativa frente a reparto disponible.
- Las zonas **urbanas y residenciales** tienden, en cambio, a que su **valor máximo habitual** quede **dentro del rango esperado** antes del umbral de saturación del panel: menos cola hacia valores extremos en el histórico mostrado.

- El estrés operativo no se reduce a “hubo muchos pedidos”: importan **cuándo** (franja, festivo), **dónde** (zona) y **qué pasaba afuera** (lluvia) y con **qué incentivos** se operaba.
- El ratio resume desbalance oferta–demanda, pero su interpretación válida es **condicional** a hora y territorio.
- Por eso el caso calibra **por zona** y el motor mira **ventanas cortas** de clima, en lugar de una sola regla global.

- **Open-Meteo:** pronóstico horario de lluvia, **sin API key** en el caso.
- Las unidades encajan con el Excel (mm por hora como intensidad).
- Zona horaria: America/Monterrey.
- Por defecto se miran unas **2 horas** hacia adelante (balance entre precisión y tiempo para reaccionar).

Qué hace el motor (pasos sencillos)

- ❶ Por zona: mira la lluvia máxima esperada frente al **umbral de esa zona**.
- ❷ Elige la zona **más preocupante** (mayor exceso sobre el umbral).
- ❸ Calcula cómo podría moverse el **ratio** con la lluvia prevista.
- ❹ Asigna **riesgo**: BAJO, MEDIO, ALTO o CRÍTICO.
- ❺ Propone **cuánto subir incentivos** y qué otras zonas vigilar.

Para no ahogar al coordinador (debounce)

- Se guarda un **estado por zona** (archivo local).
- No se repite el **mismo tipo de aviso** en poco tiempo (por defecto unos **45 minutos**), salvo que la situación **empeore de verdad** o suba mucho el **nivel de riesgo**.
- **Extra:** deduplicación del mismo “evento” de lluvia y, si se configura, tiempo mínimo entre alertas de **cualquier** zona (`ALERT_GLOBAL_MIN_INTERVAL_SEC`).

Cómo probar el motor solo

`modulo2_motor_alertas/run_alert_engine.py`

- `python run_alert_engine.py` — usa clima real, resultado en consola.
- `python run_alert_engine.py -demo` — simula lluvia fuerte en Santiago sin internet.
- `python run_alert_engine.py -recalibrate` — vuelve a armar `calibration.json` desde el Excel y ejecuta.

Reglas explicadas en lenguaje llano: `motor_reglas/motor_reglas.tex` → PDF.

- Mismo clima y **mismo motor** que el M2.
- El programa arma un **resumen en JSON** (zona, riesgo, números); el modelo de lenguaje solo **redacta** el mensaje.
- Puede usarse **Ollama** en local o **OpenAI**; con OpenAI, por defecto entra **LangChain**. Si el modelo falla, hay **texto fijo** con los mismos datos.
- El envío es con **python-telegram-bot**.

Qué debe verse en el mensaje (unos 10 segundos)

- Zona y **qué tan grave** es.
- Qué lluvia se espera y en qué ventana.
- Una frase de **contexto histórico** (guiada por el sistema).
- **Acción clara**: subir pagos de X a Y pesos en Z minutos.
- Otras **zonas a vigilar**.

- Cada cuánto se mira el clima (monitor): p. ej. cada 10 min.
- Cada cuánto se puede repetir un aviso parecido en la misma zona: p. ej. ~ 45 min.
- Si el riesgo sube de nivel, puede avisarse antes aunque no haya pasado el tiempo largo.

- **ML predictivo:** modelo de `ratio` o de probabilidad de saturación en ventanas cortas (features: lluvia prevista, hora, zona, histórico reciente), en paralelo a reglas interpretables.
- **Optimización logística:** acoplar sugerencias de incentivos con restricciones reales de flota, costo marginal y políticas comerciales; cerrar el ciclo con experimentación controlada.
- **Más señales:** demanda prevista, eventos locales, integración con despacho en vivo.

Gracias